# Manipulación y Análisis de Datos Abiertos


**Integrantes:**

Bryan Arita 12341184

Diego Rosales 12341244

**Sede de estudio:**

UNITEC Tegucigalpa

**Docente:**

Tania Lucia Meza Amador


**Sección:**

472 ÉTICA Y LEGISLACIÓN DE DATOS

**Ingeniería**

Ingeniería en Ciencia de Datos e IA

**Fecha de entrega:**

03/18/2026

**Tabla de Contenido**

Selección de sitio web....3

Pregunta de Investigación....3

Limpieza de Datos....4

Visualizar los Resultados....7

Respuesta a la pregunta de investigación....10

Directrices para Publicar....11

Marcas de Calidad....12

Licencia que utiliza....13

Conclusiones....14

Bibliografía....15

## Selección de sitio web

https://hondurasinversiones.gob.hn/DatosAbiertos

Datos suministrados por medio del Portal de Datos Abiertos de la Secretaría de Finanzas, más detalles en https://www.contratacionesabiertas.gob.hn/

## Pregunta de Investigación

¿Cuáles son las instituciones que reciben el mayor presupuesto por parte del gobierno de Honduras, según los datos del Portal de Datos Abiertos de la Secretaría de Finanzas, y determinar si los gastos públicos se realizan de forma equitativa entre las diferentes instituciones públicas?

## Limpieza de Datos

```
[1]
import pandas as pd
import numpy as np

[2]
df = pd.read_csv(
    '/content/drive/MyDrive/Colab Notebooks/202500.csv',
    encoding="latin1",
    sep=",",
    quotechar='"',
    engine="python",
    on_bad_lines='skip'
)

[3]
df.shape

(396083, 56)

[4]
df.head()
```

| | Gestion | Mes | Nivel_de_Administracion | Institucion | Gerencia_Administrativa | Unidad_Ejecutora | Programa | Subprograma | Proyecto_ | Actividad_u_Obra | ... | Dia-22 | Dia-23 | Dia-24 | Dia-25 | Dia-26 | Dia-27 | Dia-28 | Dia-29 | Dia-30 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 2025 | 1 | ADMINISTRACION CENTRAL | 0001 - Congreso Nacional | 001 - GERENCIA CENTRAL | 001 - PAGADURIA ESPECIAL | 011 - REGULACION DEL SISTEMA LEGISLATIVO | 00 - - | 000 - - | 001 - DIRECCION Y COORDINACION SUPERIOR | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| 1 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | 00 - - | 000 - - | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| 2 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | 00 - - | 000 - - | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| 3 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA | 00 - - | 000 - - | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |

Se lee el CSV descargado del sitio web mencionado anteriormente y cabe mencionar que antes de tener esta última versión, se hicieron múltiples intentos para intentar leer el conjunto de datos, pero presentaba algunos errores por el formato presentado, por lo cual se decidió ignorar filas corruptas para la implementación de este trabajo.

```
[5]
df[['cod_institucion','institucion']] = df['Institucion'].str.split(' - ', n=1, expand=True)

[6]
df.replace(['-','00 - -','000 - -'], np.nan, inplace=True)

[7]
df.head()
```

| | Gestion | Mes | Nivel_de_Administracion | Institucion | Gerencia_Administrativa | Unidad_Ejecutora | Programa | Subprograma | Proyecto_ | Actividad_u_Obra | ... | Dia-24 | Dia-25 | Dia-26 | Dia-27 | Dia-28 | Dia-29 | Dia-30 | Dia-31 | cod_in |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 2025 | 1 | ADMINISTRACION CENTRAL | 0001 - Congreso Nacional | 001 - GERENCIA CENTRAL | 001 - PAGADURIA ESPECIAL | 011 - REGULACION DEL SISTEMA LEGISLATIVO | NaN | NaN | 001 - DIRECCION Y COORDINACION SUPERIOR | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | |
| 1 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | NaN | NaN | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | |
| 2 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | NaN | NaN | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | |
| 3 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | NaN | NaN | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | |
| 4 | 2025 | 1 | ADMINISTRACION CENTRAL | 0002 - Tribunal Superior de Cuentas | 001 - GERENCIA CENTRAL | 001 - COORDINACION SUPERIOR EJECUTIVA | 011 - CONTROL DEL MANEJO DE LOS RECURSOS PARA ... | NaN | NaN | 001 - DIRECCION SUPERIOR Y FISCALIZACION A POS... | ... | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | |

5 rows × 58 columns

Se realizo una separación del código de la institución y su nombre para poder agrupar correctamente. Posteriormente se realizó una modificación para quitar el formato 00 - - que

tenían algunas celdas, por lo cual se eliminar valores basuras y así se evita ruido en otras variables.

```
df.info()

 1  Mes                        396083 non-null  int64
 2  Nivel_de_Administracion    396083 non-null  object
 3  Institucion                396083 non-null  object
 4  Gerencia_Administrativa    396083 non-null  object
 5  Unidad_Ejecutora           396083 non-null  object
 6  Programa                   396083 non-null  object
 7  Subprograma                20270 non-null   object
 8  Proyecto_                  30938 non-null   object
 9  Actividad_u_Obra           396083 non-null  object
 10 Organismo                  396083 non-null  object
 11 Fuente_de_Financiamiento   396083 non-null  object
 12 BIP                        21857 non-null   object
 13 Finalidad                  396083 non-null  object
 14 Funcion                    396083 non-null  object
 15 Grupo_de_Objeto            396083 non-null  object
 16 Objeto_del_Gasto           396083 non-null  object
 17 Beneficiario_de_Transferencia 396083 non-null  object
 18 Aprobado_Ministro          396083 non-null  float64
 19 Aprobado                   396083 non-null  float64
 20 Vigente                    396083 non-null  float64
 21 Ejecucion_de_enero         396083 non-null  float64
 22 Ejecucion_Acumulada        396083 non-null  float64
 23 Disponible                 396083 non-null  float64
 24 %_de_Ejecucion             396083 non-null  float64
 25 Dia-1                      396083 non-null  float64
 26 Dia-2                      396083 non-null  float64
 27 Dia-3                      396083 non-null  float64
 28 Dia-4                      396083 non-null  float64
 29 Dia-5                      396083 non-null  float64
 30 Dia-6                      396083 non-null  float64
 31 Dia-7                      396083 non-null  float64
 32 Dia-8                      396083 non-null  float64
 33 Dia-9                      396083 non-null  float64
 34 Dia-10                     396083 non-null  float64
 35 Dia-11                     396083 non-null  float64
 36 Dia-12                     396083 non-null  float64
 37 Dia-13                     396083 non-null  float64
 38 Dia-14                     396083 non-null  float64
 39 Dia-15                     396083 non-null  float64
 40 Dia-16                     396083 non-null  float64
 41 Dia-17                     396083 non-null  float64
 42 Dia-18                     396083 non-null  float64
 43 Dia-19                     396083 non-null  float64
 44 Dia-20                     396083 non-null  float64
 45 Dia-21                     396083 non-null  float64
 46 Dia-22                     396083 non-null  float64
 47 Dia-23                     396083 non-null  float64
 48 Dia-24                     396083 non-null  float64
 49 Dia-25                     396083 non-null  float64
 50 Dia-26                     396083 non-null  float64
 51 Dia-27                     396083 non-null  float64
 52 Dia-28                     396083 non-null  float64
 53 Dia-29                     396083 non-null  float64
 54 Dia-30                     396083 non-null  float64
 55 Dia-31                     391112 non-null  object
 56 cod_institucion            396083 non-null  object
 57 institucion                396083 non-null  object
dtypes: float64(37), int64(2), object(19)
```

Es esencial entender que tipo de dato es cada variable para verificar si ocuparan diferentes tipos de limpieza o validaciones.

```
df.duplicated().sum()

np.int64(0)

df.shape

(396083, 58)

df = df[df['Vigente'] > 0]
df.shape

(367930, 58)

df.groupby('institucion')['Vigente'].sum()
```

| institucion | Vigente |
|---|---|
| Administracion Aduanera de Honduras | 1.387274e+10 |
| Administracion Nacional de Servicio Civil | 1.027911e+09 |
| Agencia Hondurena de Aeronautica Civil | 3.012894e+09 |
| Agencia de Regulacion Sanitaria | 3.123688e+09 |
| Banco Central de Honduras | 9.007526e+10 |
| ... | ... |
| Unidad Especial de Proteccion | 3.650000e+09 |
| Universidad Nacional Autonoma de Honduras | 6.630905e+10 |
| Universidad Nacional de Agricultura | 7.153751e+09 |
| Universidad Pedagogica Nacional Francisco Morazan | 8.490781e+09 |
| Universidad de Ciencias Forestales | 2.222198e+09 |

114 rows × 1 columns

dtype: float64

```
df.shape
```

Verificamos que no existan valores duplicaos y visualizamos el tamaño del dataset. Luego se eliminaron las tuplas que tenían un valor menor o igual que 0 , ya que para el problema

de investigación declarado se ocupa que las instituciones contengan información en la variable “vigente”, ya que esta es la que identifica el presupuesto real asignado disponible.

```
16]
0 s
df = df.drop(columns=[col for col in df.columns if 'Dia-' in col])
df.columns

Index(['Gestion', 'Mes', 'Nivel_de_Administracion', 'Institucion',
       'Gerencia_Administrativa', 'Unidad_Ejecutora', 'Programa',
       'Subprograma', 'Proyecto_', 'Actividad_u_Obra', 'Organismo',
       'Fuente_de_Financiamiento', 'BIP', 'Finalidad', 'Funcion',
       'Grupo_de_Objeto', 'Objeto_del_Gasto', 'Beneficiario_de_Transferencia',
       'Aprobado_Ministro', 'Aprobado', 'Vigente', 'Ejecucion_de_enero',
       'Ejecucion_Acumulada', 'Disponible', '%_de_Ejecucion',
       'cod_institucion', 'institucion'],
      dtype='object')

17]
0 s
df['porcentaje_ejecucion'] = df['Ejecucion_Acumulada'] / df['Vigente']

18]
0 s
df.columns

Index(['Gestion', 'Mes', 'Nivel_de_Administracion', 'Institucion',
       'Gerencia_Administrativa', 'Unidad_Ejecutora', 'Programa',
       'Subprograma', 'Proyecto_', 'Actividad_u_Obra', 'Organismo',
       'Fuente_de_Financiamiento', 'BIP', 'Finalidad', 'Funcion',
       'Grupo_de_Objeto', 'Objeto_del_Gasto', 'Beneficiario_de_Transferencia',
       'Aprobado_Ministro', 'Aprobado', 'Vigente', 'Ejecucion_de_enero',
       'Ejecucion_Acumulada', 'Disponible', '%_de_Ejecucion',
       'cod_institucion', 'institucion', 'porcentaje_ejecucion'],
      dtype='object')
```

Se eliminaron del dataset todas las columnas de los dias, ya que no son necesarias para el objetivo de esta investigación.  Posteriormente se crea una nueva variable para medir que eficientemente son las instituciones al ejecutar el presupuesto.

## Visualizar los Resultados

```
[30]
✓ 0s
instituciones_vig=df.groupby('institucion')['Vigente'].sum().sort_values(ascending=False)
mejores_inst=instituciones_vig.head(10)
mejores_inst
```

| institucion | Vigente |
|---|---|
| Deuda Publica | 6.611808e+11 |
| Empresa Nacional de Energia Electrica | 4.438050e+11 |
| Secretaria de Educacion | 4.387794e+11 |
| Secretaria de Salud | 2.904579e+11 |
| Instituto Nacional de Prevision del Magisterio | 2.631045e+11 |
| Instituto Hondureno de Seguridad Social | 1.798788e+11 |
| Secretaria de Infraestructura y Transporte | 1.518877e+11 |
| Inst. Nal. de Jubi.y Pen. de los Emp. y Fun. del Poder Ejec. | 1.164240e+11 |
| Secretaria de Defensa Nacional | 1.164231e+11 |
| Secretaria de Seguridad | 1.155075e+11 |

dtype: float64

Para iniciar la fase de visualizar los resultados es importante agrupar los datos dependiendo del objetivo. En este contexto, se creó un nuevo datsaset derivado en donde se agrupa la institución con la suma de todos sus presupuestos (vigente).

```
[21]
✓ 0s
import matplotlib.pyplot as plt
mejores_inst = mejores_inst / 1e9
mejores_inst.plot(kind='bar')
plt.title('Las 10 instituciones con mayor presupuesto')
plt.ylabel('Presupuesto (miles de millones)')
plt.xticks(rotation=90)
plt.show()
```

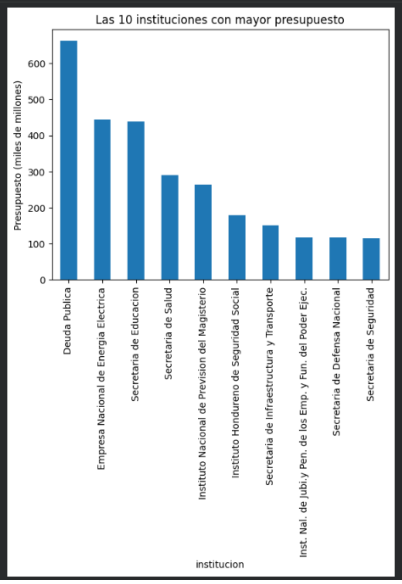


El primer grafico muestra las primeras 10 instituciones

```
porcentaje = instituciones_vig / instituciones_vig.sum()
top10_pct = porcentaje.head(10)
```

```
top10_pct.plot(kind='pie', autopct='%1.1f%%')
plt.title('Distribución del presupuesto de los primeros 10')
plt.ylabel('')
plt.show()
```

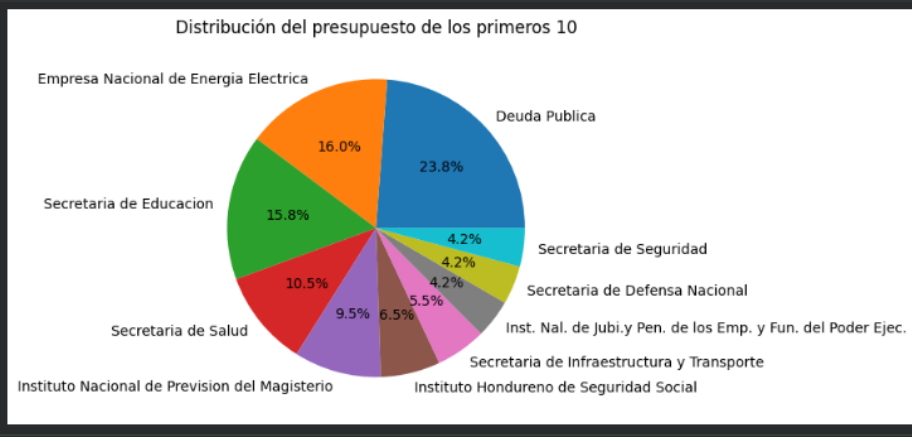


```
eficiencia = df.groupby('institucion').agg({'Vigente':'sum','Ejecucion_Acumulada':'sum'})
eficiencia['ratio'] = eficiencia['Ejecucion_Acumulada'] / eficiencia['Vigente']
```

```
eficiencia.sort_values('ratio', ascending=False).head(10)['ratio'].plot(kind='bar')
plt.title('Instituciones con mayor ejecución')
plt.show()
```

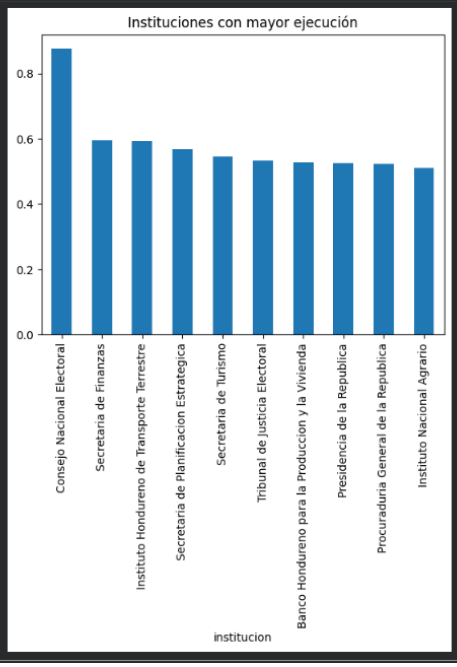

```python
df[['cod_finalidad','finalidad']] = df['Finalidad'].str.split(' - ', n=1, expand=True)
```

```python
sector = df.groupby('finalidad')['Vigente'].sum().sort_values(ascending=False)
print(sector.head(10))
```

```
finalidad
SERVICIOS PUBLICOS GENERALES                                  1.010635e+12
ASUNTOS ECONOMICOS                                            8.791459e+11
PROTECCION SOCIAL                                             5.994232e+11
EDUCACION INVESTIGACION CULTURA Y ACTIVIDADES RECREATIVAS      5.099082e+11
SERVICIOS DE SALUD                                            3.457871e+11
DEFENSA Y SEGURIDAD                                           3.286984e+11
VIVIENDA Y SERVICIOS COMUNITARIOS                             2.205360e+10
PROTECCION DEL MEDIO AMBIENTE                                 1.323464e+10
Name: Vigente, dtype: float64
```

```python
sector.head(10).plot(kind='bar')
plt.title('Presupuesto por finalidad')
plt.ylabel('Presupuesto Vigente')
plt.xticks(rotation=90)
plt.show()
```

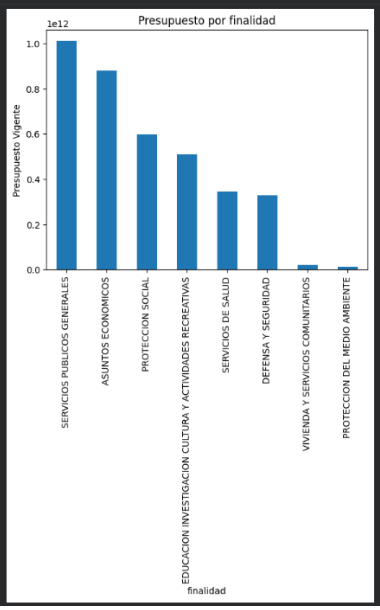

## Respuesta a la pregunta de investigación

El análisis revela una distribución presupuestaria desigual en Honduras. El gasto se concentra en pocas instituciones, especialmente en el pago de la deuda pública y sectores clave como energía, educación y salud. Además, hay variaciones en la eficiencia de ejecución, con algunas instituciones alcanzando altos porcentajes y otras quedándose en niveles más bajos. Por lo que se puede llegar a concluir que predomina el enfoque en el funcionamiento del Estado y el desarrollo económico, relegando áreas como vivienda y medio ambiente a una menor proporción.

## Directrices para Publicar

Este conjunto de datos se publicó bajo directrices de datos abiertos establecidas por el gobierno, esto promueve la transparencia, y el libre acceso a los datos. Estas directrices nos dicen que los datos deben de estar en un formato accesible, y abierto, con una correcta estructura para hacer su análisis más simple. Se busca que la información se actualice regularmente, y que este conjunto tenga permitido ser usado para fines académicos o de investigación.

## Marcas de Calidad

Este dataset cumple con varios estándares de calidad de datos abiertos. Entre ellos se encuentran:

- Accesibilidad → Disponible de forma pública y no tiene restricciones.
- Formato Abierto → Por su tipo de formato se puede utilizar en herramientas como R, PowerBI, Python, etc.
- Reutilización → Se puede usar para diferentes tipos de propósitos, investigaciones, proyectos, etc.
- Estandarización → Su estructura es organizada, por lo que el proceso de limpieza suele ser estándar y sencillo para cualquier software estadístico.
- Actualización → Este dataset está en constante actualización, la más reciente siendo realizada el día de hoy (3 de marzo de 2026), por lo que el dataset contiene datos actuales.

Sin embargo, no es un dataset perfecto, cuenta con algunos errores comunes, como los valores nulos, por ejemplo.

**Licencia que utiliza**

Este conjunto de datos esta publicado bajo la licencia Creative Commons Reconocimiento 4.0 Internacional, esta licencia permite el uso, la reproducción, y poder adaptar la información siempre que se le reconozca a la fuente original. Con esta licencia se garantiza la libre reutilización de los datos, y promueve la transparencia y un acceso libre a la información pública. Por lo tanto, este dataset puede ser usado para investigaciones, análisis, o desarrollos de proyecto siempre y cuando se respete al autor original.

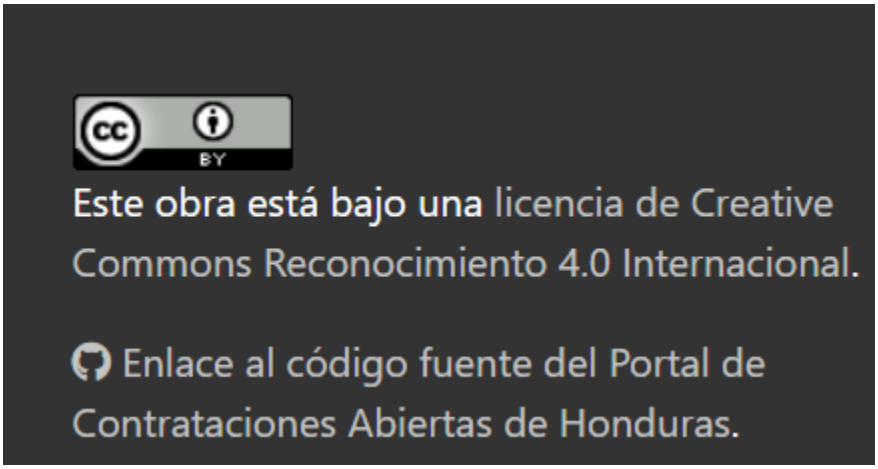

## Conclusiones

Podemos concluir, después de analizar profundamente el dataset del Presupuesto General de Honduras, que la asignación del gasto público no es distribuida equitativamente entre las instituciones públicas, pudimos observar una concentración alta en algunas. Instituciones como la deuda pública, la ENEE, y el sector de educación son los que absorben mayor porcentaje en el presupuesto total, lo que deja en evidencia que el estado da prioridad a sectores estratégicos, y el funcionamiento de los servicios que ellos consideran esenciales. También pudimos identificar las diferencias en la ejecución de presupuestos de las instituciones, lo que deja en evidencia que no todas las instituciones administran eficientemente sus presupuestos.

Este proyecto nos permitió experimentar de primera mano el valor y los contratiempos de trabajar con datos abiertos. Pudimos comprobar que estos datasets hacen más fácil el acceso a la información relevante, aumenta la transparencia y el análisis independiente de estudiantes o investigadores. También identificamos algunos retos, como realizar un proceso de limpieza, transformar datos y validar en casos de inconsistencias o valores faltantes en el dataset. Este proyecto nos demostró que el correcto uso de datos abiertos no es solo técnico, sino también un entendimiento teórico de sus condiciones de uso, y su responsabilidad a la hora de interpretar la información.

**Bibliografía**

de, G. (2024). HondurasInversiones - Iniciativa de Mapainversiones. Hondurasinversiones.gob.hn. https://hondurasinversiones.gob.hn/DatosAbiertos

Portal de Contrataciones Abiertas de Honduras - Inicio. (2026). Contratacionesabiertas.gob.hn. https://www.contratacionesabiertas.gob.hn/